

I Poziom TLR

Wraz z dynamicznym rozwojem generatywnej sztucznej inteligencji, w tym modeli takich jak Sora od OpenAI czy Nano Banana od Google, coraz trudniej odróżnić materiały autentyczne od treści generowanych przez AI. Zjawisko to stanowi zagrożenie dla wiarygodności informacji w Internecie i sprzyja szerzeniu się dezinformacji. Przykładowo, deepfake'i nagranie wideo polityków w sytuacjach, których nigdy nie przeżyli, czy fałszywe nagranie audio podszywające się pod głosy znanych osób w celu wyłudzenia pieniędzy, pokazują realne konsekwencje takich technologii.

W odpowiedzi na ten problem opracowaliśmy koncepcję aplikacji webowej, która umożliwiałaby automatyczną detekcję treści wideo oraz obrazów generowanych przez sztuczną inteligencję. Aplikacja analizowałaby dwa główne obszary: metadane pliku oraz charakterystyczne artefakty cyfrowe, takie jak nienaturalne cienie i odbicie, migotanie detali w tle, sztuczna, "plastikowa" tekstura oraz zrobotyzowana czystość i modulacja głosu. Obecnie na rynku dostępne są rozwiązania pozwalające weryfikować autentyczność treści internetowych, jednak większość z nich skupia się wyłącznie na jednym rodzaju analizy – na przykład tylko na obrazie lub tylko na wideo – i często pomija inne źródła informacji, takie jak dźwięk czy metadane. Nasza koncepcja zakłada stworzenie zintegrowanej aplikacji webowej, która analizowałaby jednocześnie kilka poziomów danych, co znacząco zwiększyło by skuteczność detekcji.

W przyszłości takie rozwiązanie mogłoby znaleźć zastosowanie m.in. w mediach społecznościowych serwisach informacyjnych oraz systemach weryfikacji treści wykorzystywanych przez administrację publiczną. Dostęp do naszej aplikacji byłby w pełni darmowy, dzięki czemu każdy użytkownik Internetu mógłby skutecznie chronić się przed dezinformacją.

II Poziom TLR

Na podstawie analizy z I Poziomu TLR, zidentyfikowaliśmy rosnący problem dezinformacji generowanej przez AI. Podczas burzy mózgów wymyśliliśmy zastosowania dla naszej technologii.

1. Rozszerzenie do przeglądarki chroniące przed dezinformacją

Naszym głównym pomysłem jest stworzenie rozszerzenia do przeglądarki, które integrowałoby się z mediami społecznościowymi takimi jak Facebook, X czy Tiktok. Przeglądając media społecznościowe idzie natrafić się na komentarze typu „Czy to naprawdę”, „Czy on naprawdę to zrobił/powiedział”. Osoby piszące takie komentarze nie są po prostu świadomi aktualnych możliwości technologicznych. Nasze rozszerzenie w czasie rzeczywistym, analizowałoby przeglądane przez użytkownika

treści i w momencie natrafienia na materiał, który z dużym prawdopodobieństwem został wygenerowany przez sztuczną inteligencję, narzędzie wyświetlałoby ostrzeżenie, że materiał nie jest prawdziwy. Celem tego rozwiązania byłoby dotarcie do masowego odbiorcy i ochrona użytkowników przed dezinformacją.

2. Ochrona własności intelektualnej artystów i twórców cyfrowych

Drugim potencjalnym zastosowaniem jest stworzenie systemu dedykowanego ochronie praw autorskich artystów. Widzimy, jak coraz częściej modele AI są trenowane na pracach twórców bez ich zgody, a następnie bezprawnie kopiuje ich **unikalny styl**. Nasza technologia mogłaby stanowić rdzeń platformy, na której artyści mogliby "rejestrować" swoje prace, tworząc dla nich cyfrowy certyfikat autentyczności i unikalny "odcisk" ich stylu. Następnie nasz algorytm monitorowałby internet, analizując nowo powstałe obrazy AI. Gdyby wykrył, że dany obraz został wygenerowany w oparciu o styl zarejestrowanego artysty, **system informowałby o tym twórcę**, dostarczając dowód na naruszenie jego własności intelektualnej. W ten sposób dalibyśmy artystom realne narzędzie do walki o swoje prawa i ochronę ich artystycznej tożsamości.

3. Aplikacja mobilna do wykrywania oszustw głosowych

Trzecim, zastosowaniem byłaby aplikacja mobilna skoncentrowana na osobistym bezpieczeństwie. Aktualnie oszuści poszli o krok dalej z oszustwami na „wnuczka” i kopiuje nawet głos bliskiej osoby aby wyłudzić pieniądze. Nasza aplikacja działałaby w tle podczas rozmów telefonicznych. Analizowałaby głos rozmówcy w czasie rzeczywistym, poszukując nieprawidłowości w głosie. W przypadku wykrycia anomalii, aplikacja natychmiast wyświetlałaby komunikat o potencjalnym zagrożeniu, dając szansę na uniknięcia oszustwa i ochronę swoich oszczędności.