

I Poziom TLR

Wraz z dynamicznym rozwojem generatywnej sztucznej inteligencji, w tym modeli takich jak Sora od OpenAI czy Nano Banana od Google, coraz trudniej odróżnić materiały autentyczne od treści generowanych przez AI. Zjawisko to stanowi zagrożenie dla wiarygodności informacji w Internecie i sprzyja szerzeniu się dezinformacji. Przykładowo, deepfake'i nagranie wideo polityków w sytuacjach, których nigdy nie przeżyli, czy fałszywe nagranie audio podszywające się pod głosy znanych osób w celu wyłudzenia pieniędzy, pokazują realne konsekwencje takich technologii.

W odpowiedzi na ten problem opracowaliśmy koncepcję aplikacji webowej, która umożliwiałaby automatyczną detekcję treści wideo oraz obrazów generowanych przez sztuczną inteligencję. Aplikacja analizowałaby dwa główne obszary: metadane pliku oraz charakterystyczne artefakty cyfrowe, takie jak nienaturalne cienie i odbicie, migotanie detali w tle, sztuczna, "plastikowa" tekstura oraz zrobotyzowana czystość i modulacja głosu. Obecnie na rynku dostępne są rozwiązania pozwalające weryfikować autentyczność treści internetowych, jednak większość z nich skupia się wyłącznie na jednym rodzaju analizy – na przykład tylko na obrazie lub tylko na wideo – i często pomija inne źródła informacji, takie jak dźwięk czy metadane. Nasza koncepcja zakłada stworzenie zintegrowanej aplikacji webowej, która analizowałaby jednocześnie kilka poziomów danych, co znacząco zwiększyło by skuteczność detekcji.

W przyszłości takie rozwiązanie mogłoby znaleźć zastosowanie m.in w mediach społecznościowych serwisach informacyjnych oraz systemach weryfikacji treści wykorzystywanych przez administrację publiczną. Dostęp do naszej aplikacji byłby w pełni darmowy, dzięki czemu każdy użytkownik Internetu mógłby skutecznie chronić się przed dezinformacją.

II Poziom TLR

Na podstawie analizy z I Poziomu TLR, zidentyfikowaliśmy rosnący problem dezinformacji generowanej przez AI. Podczas burzy mózgów wymyśliliśmy zastosowania dla naszej technologii.

1. Rozszerzenie do przeglądarki chroniące przed dezinformacją

Naszym głównym pomysłem jest stworzenie rozszerzenia do przeglądarki, które integrowałoby się z mediami społecznościowymi takimi jak Facebook, X czy Tiktok. Przeglądając media społecznościowe idzie natrafić się na komentarze typu „Czy to naprawdę”, „Czy on naprawdę to zrobił/powiedział”. Osoby piszące takie komentarze nie są po prostu świadomi aktualnych możliwości technologicznych. Nasze rozszerzenie w czasie

rzeczywistym, analizowałoby przeglądane przez użytkownika treści i w momencie natrafienia na materiał, który z dużym prawdopodobieństwem został wygenerowany przez sztuczną inteligencję, narzędzie wyświetlałoby ostrzeżenie, że materiał nie jest prawdziwy. Celem tego rozwiązania byłoby dotarcie do masowego odbiorcy i ochrona użytkowników przed dezinformacją.

2. Ochrona własności intelektualnej artystów i twórców cyfrowych

Drugim potencjalnym zastosowaniem jest stworzenie systemu dedykowanego ochronie praw autorskich artystów. Widzimy, jak coraz częściej modele AI są trenowane na pracach twórców bez ich zgody, a następnie bezprawnie kopiują ich **unikalny styl**. Nasza technologia mogłaby stanowić rdzeń platformy, na której artyści mogliby "rejestrować" swoje prace, tworząc dla nich cyfrowy certyfikat autentyczności i unikalny "odcisk" ich stylu. Następnie nasz algorytm monitorowałby internet, analizując nowo powstałe obrazy AI. Gdyby wykrył, że dany obraz został wygenerowany w oparciu o styl zarejestrowanego artysty, **system informowałby o tym twórcę**, dostarczając dowód na naruszenie jego własności intelektualnej. W ten sposób dalibyśmy artystom realne narzędzie do walki o swoje prawa i ochronę ich artystycznej tożsamości.

3. Aplikacja mobilna do wykrywania oszustw głosowych

Trzecim, zastosowaniem byłaby aplikacja mobilna skoncentrowana na osobistym bezpieczeństwie. Aktualnie oszuści poszli o krok dalej z oszustwami na „wnuczka” i kopiują nawet głos bliskiej osoby aby wyłudzić pieniądze. Nasza aplikacja działałaby w tle podczas rozmów telefonicznych. Analizowałaby głos rozmówcy w czasie rzeczywistym, poszukując nieprawidłowości w głosie. W przypadku wykrycia anomalii, aplikacja natychmiast wyświetlałaby komunikat o potencjalnym zagrożeniu, dając szansę na uniknięcia oszustwa i ochronę swoich oszczędności.

4. Narzędzie dla Dziennikarzy i Fact-checkerów

Proponujemy stworzenie profesjonalnego narzędzia, które mogłoby działać w modelu subskrypcyjnym i byłoby dedykowane redakcjom oraz organizacjom zajmującym się weryfikacją faktów. Narzędzie to umożliwiłoby szybkie weryfikowanie autentyczności zdjęć, nagrań i filmów otrzymywanych od informatorów lub znalezionych w Internecie, jeszcze przed publikacją materiału. W dzisiejszym świecie, gdzie wiarygodność informacji jest bezcenna, takie rozwiązanie stanowiłoby kluczowe wsparcie w walce z dezinformacją..

5. Bezpieczeństwo w Aplikacjach Randkowych

Równocześnie proponujemy integrację naszego systemu weryfikacji zdjęć profilowych z aplikacjami randkowymi. Nasza technologia umożliwi identyfikację fałszywych kont i "catfishingu", znacząco podnosząc poziom bezpieczeństwa użytkowników platform randkowych.

Lista rzeczy potrzebnych:

1. 3x PyCharm Pro z JetBrains AI Pro
2. 3x laptop z kartą GeForce serii 5000
3. Dostęp światłowodowy do internetu
4. Usługi chmurowe
5. Zewnętrzna pamięć SSD o dużej pojemności
6. Licencje na oprogramowanie do obliczeń rozproszonych
7. Wysokiej jakości karta dźwiękowa i mikrofon
8. Licencja do SORA2 i NanoBanana

III Poziom TLR

1. Rozszerzenie do przeglądarki chroniące przed dezinformacją

Przeanalizowaliśmy możliwość stworzenia rozszerzenia, które mogłoby wykrywać fałszywe treści w mediach społecznościowych.

Zrobiliśmy przegląd dokumentacji przeglądarek (np. Chrome i Firefox) i potwierdziliśmy, że istnieje możliwość tworzenia dodatków, które analizują zawartość przeglądanych stron. Wstępnie oceniliśmy, że można byłoby przekazywać linki do materiałów (np. filmów lub obrazów) do naszej aplikacji w celu analizy.

2. Ochrona własności intelektualnej artystów i twórców cyfrowych

Zastanowiliśmy się, jak mógłby działać system rozpoznający styl artysty.

W Internecie są już przykłady programów, które potrafią naśladować styl malarza, więc podobne rozwiązanie można by wykorzystać do rozpoznawania prac.

Wystarczyłoby zebrać prace artystów w bazie danych i porównywać nowe obrazy z tymi zapisanymi, żeby sprawdzić, czy są do siebie podobne.

3. Aplikacja mobilna do wykrywania oszustw głosowych

Sprawdziliśmy, że współczesne telefony pozwalają analizować dźwięk w czasie rzeczywistym (np. przez mikrofon lub aplikacje nagrywające).

Na tej podstawie można byłoby stworzyć aplikację, która porównuje głos rozmówcy z zapisanym wcześniej wzorcem. Z technicznego punktu widzenia jest to możliwe do zrealizowania ale jest to wątpliwe ze strony prawnej.

4. Narzędzie dla Dziennikarzy i Fact-checkerów

Sprawdziliśmy, jak działają popularne narzędzia do weryfikacji zdjęć, takie jak Google Lens czy TinEye. Na tej podstawie uznaliśmy, że nasze rozwiązanie mogłoby działać podobnie, ale dodatkowo analizować też dźwięk i metadane pliku.

Zauważyliśmy, że nawet porównując dwa podobne zdjęcia, można łatwo znaleźć różnice w metadanych, na przykład w dacie utworzenia.

5. Bezpieczeństwo w Aplikacjach Randkowych

Rozważyliśmy możliwość połączenia naszej technologii z aplikacjami randkowymi. Z technicznego punktu widzenia można byłoby analizować zdjęcia profilowe użytkowników i sprawdzać, czy nie są wygenerowane przez AI. Na razie byłby to proces ręczny (użytkownik przesyła zdjęcie do sprawdzenia), ale w przyszłości można byłoby to zautomatyzować.