

2025-01-01


System detekcji treści generowanych przez sztuczną inteligencję w mediach cyfrowych

Zarządzanie projektem informatycznym

Łukasz Przewodowski(kierownik)

Borys Pakosz

Marcel Szeluga



Spis treści

I Poziom TLR.....	2
II Poziom TLR.....	2
1. Rozszerzenie do przeglądarki chroniące przed dezinformacją	2
2. Ochrona własności intelektualnej artystów i twórców cyfrowych	3
3. Aplikacja mobilna do wykrywania oszustw głosowych.....	3
4. Narzędzie dla Dziennikarzy i Fact-checkerów	3
5. Bezpieczeństwo w Aplikacjach Randkowych	3
Lista rzeczy potrzebnych do realizacji projektu:	4
III Poziom TLR.....	4
1. Rozszerzenie do przeglądarki chroniące przed dezinformacją	4
2. Ochrona własności intelektualnej artystów i twórców cyfrowych	4
3. Aplikacja mobilna do wykrywania oszustw głosowych.....	4
4. Narzędzie dla Dziennikarzy i Fact-checkerów	5
5. Bezpieczeństwo w Aplikacjach Randkowych	5
IV Poziom TLR.....	5
Moduł analizy obrazów:.....	5
Moduł analizy filmów:	6
Moduł analizy rozmów telefonicznych:.....	6
Grupy Docelowe.....	7
Możliwe ścieżki komercjalizacji	8
V Poziom TLR.....	8

I Poziom TLR

Wraz z dynamicznym rozwojem generatywnej sztucznej inteligencji, w tym modeli takich jak Sora od OpenAI czy Nano Banana od Google, coraz trudniej odróżnić materiały autentyczne od treści generowanych przez AI. Zjawisko to stanowi zagrożenie dla wiarygodności informacji w Internecie i sprzyja szerzeniu się dezinformacji. Przykładowo, deepfake'i nagranie wideo polityków w sytuacjach, których nigdy nie przeżyli, czy fałszywe nagranie audio podszywające się pod głosy znanych osób w celu wyłudzenia pieniędzy, pokazują realne konsekwencje takich technologii.

W odpowiedzi na ten problem opracowaliśmy koncepcję aplikacji webowej, która umożliwiałaby automatyczną detekcję treści wideo oraz obrazów generowanych przez sztuczną inteligencję. Aplikacja analizowałaby dwa główne obszary: metadane pliku oraz charakterystyczne artefakty cyfrowe, takie jak nienaturalne cienie i odbicie, migotanie detali w tle, sztuczna, "plastikowa" tekstura oraz zrobotyzowana czystość i modulacja głosu. Obecnie na rynku dostępne są rozwiązania pozwalające weryfikować autentyczność treści internetowych, jednak większość z nich skupia się wyłącznie na jednym rodzaju analizy – na przykład tylko na obrazie lub tylko na wideo – i często pomija inne źródła informacji, takie jak dźwięk czy metadane. Nasza koncepcja zakłada stworzenie zintegrowanej aplikacji webowej, która analizowałaby jednocześnie kilka poziomów danych, co znacząco zwiększyło by skuteczność detekcji.

W przyszłości takie rozwiązanie mogłoby znaleźć zastosowanie m.in. w mediach społecznościowych serwisach informacyjnych oraz systemach weryfikacji treści wykorzystywanych przez administrację publiczną. Dostęp do naszej aplikacji byłby w pełni darmowy, dzięki czemu każdy użytkownik Internetu mógłby skutecznie chronić się przed dezinformacją.

II Poziom TLR

Na podstawie analizy z I Poziomu TLR, zidentyfikowaliśmy rosnący problem dezinformacji generowanej przez AI. Podczas burzy mózgów wymyśliliśmy zastosowania dla naszej technologii.

1. Rozszerzenie do przeglądarki chroniące przed dezinformacją

Naszym głównym pomysłem jest stworzenie rozszerzenia do przeglądarki, które integrowałoby się z mediami społecznościowymi takimi jak Facebook, X czy Tiktok. Przeglądając media społecznościowe idzie natrafić się na komentarze typu „Czy to naprawdę”, „Czy on naprawdę to zrobił/powiedział”. Osoby piszące takie komentarze nie są po prostu świadomi aktualnych możliwości technologicznych. Nasze rozszerzenie w czasie rzeczywistym, analizowałoby przeglądane przez użytkownika treści i w momencie natrafienia na materiał, który z dużym prawdopodobieństwem został wygenerowany przez sztuczną inteligencję, narzędzie wyświetlałoby ostrzeżenie, że materiał nie jest

prawdziwy. Celem tego rozwiązania byłoby dotarcie do masowego odbiorcy i ochrona użytkowników przed dezinformacją.

2. Ochrona własności intelektualnej artystów i twórców cyfrowych

Drugim potencjalnym zastosowaniem jest stworzenie systemu dedykowanego ochronie praw autorskich artystów. Widzimy, jak coraz częściej modele AI są trenowane na pracach twórców bez ich zgody, a następnie bezprawnie kopiuje ich **unikalny styl**. Nasza technologia mogłaby stanowić rdzeń platformy, na której artyści mogliby "rejestrować" swoje prace, tworząc dla nich cyfrowy certyfikat autentyczności i unikalny "odcisk" ich stylu. Następnie nasz algorytm monitorowałby internet, analizując nowo powstałe obrazy AI. Gdyby wykrył, że dany obraz został wygenerowany w oparciu o styl zarejestrowanego artysty, **system informowałby o tym twórcę**, dostarczając dowód na naruszenie jego własności intelektualnej. W ten sposób dalibyśmy artystom realne narzędzie do walki o swoje prawa i ochronę ich artystycznej tożsamości.

3. Aplikacja mobilna do wykrywania oszustw głosowych

Trzecim, zastosowaniem byłaby aplikacja mobilna skoncentrowana na osobistym bezpieczeństwie. Aktualnie oszuści poszli o krok dalej z oszustwami na „wnuczka” i kopiuje nawet głos bliskiej osoby aby wyłudzić pieniądze. Nasza aplikacja działałaby w tle podczas rozmów telefonicznych. Analizowałaby głos rozmówcy w czasie rzeczywistym, poszukując nieprawidłowości w głosie. W przypadku wykrycia anomalii, aplikacja natychmiast wyświetlałaby komunikat o potencjalnym zagrożeniu, dając szansę na uniknięcia oszustwa i ochronę swoich oszczędności.

4. Narzędzie dla Dziennikarzy i Fact-checkerów

Proponujemy stworzenie profesjonalnego narzędzia, które mogłoby działać w modelu subskrypcyjnym i byłoby dedykowane redakcjom oraz organizacjom zajmującym się weryfikacją faktów. Narzędzie to umożliwiłoby szybkie weryfikowanie autentyczności zdjęć, nagrań i filmów otrzymywanych od informatorów lub znalezionych w Internecie, jeszcze przed publikacją materiału. W dzisiejszym świecie, gdzie wiarygodność informacji jest bezcenna, takie rozwiązanie stanowiłoby kluczowe wsparcie w walce z dezinformacją..

5. Bezpieczeństwo w Aplikacjach Randkowych

Równocześnie proponujemy integrację naszego systemu weryfikacji zdjęć profilowych z aplikacjami randkowymi. Nasza technologia umożliwi identyfikację fałszywych kont i "catfishingu", znacząco podnosząc poziom bezpieczeństwa użytkowników platform randkowych.

Lista rzeczy potrzebnych do realizacji projektu:

1. 3x PyCharm Pro z JetBrains AI Pro
2. 3x laptop z kartą GeForce serii 5000
3. Dostęp światłowodowy do internetu
4. Usługi chmurowe
5. Zewnętrzna pamięć SSD o dużej pojemności
6. Licencje na oprogramowanie do obliczeń rozproszonych
7. Wysokiej jakości karta dźwiękowa i mikrofon
8. Licencja do SORA2 i NanoBanana

III Poziom TLR

1. Rozszerzenie do przeglądarki chroniące przed dezinformacją

Przeanalizowaliśmy możliwość stworzenia rozszerzenia, które mogłoby wykrywać fałszywe treści w mediach społecznościowych. Zrobiliśmy przegląd dokumentacji przeglądarek (np. Chrome i Firefox) i potwierdziliśmy, że istnieje możliwość tworzenia dodatków, które analizują zawartość przeglądanych stron. Wstępnie oceniliśmy, że można byłoby przekazywać linki do materiałów (np. filmów lub obrazów) do naszej aplikacji w celu analizy.

2. Ochrona własności intelektualnej artystów i twórców cyfrowych

Zastanowiliśmy się, jak mógłby działać system rozpoznający styl artysty. W Internecie są już przykłady programów, które potrafią naśladować styl malarza, więc podobne rozwiązanie można by wykorzystać do rozpoznawania prac. Wystarczyłoby zebrać prace artystów w bazie danych i porównywać nowe obrazy z tymi zapisanymi, żeby sprawdzić, czy są do siebie podobne.

3. Aplikacja mobilna do wykrywania oszustw głosowych

Sprawdziliśmy, że współczesne telefony pozwalają analizować dźwięk w czasie rzeczywistym (np. przez mikrofon lub aplikacje nagrywające). Na tej podstawie można byłoby stworzyć aplikację, która porównuje głos rozmówcy z zapisanym wcześniej wzorcem. Z technicznego punktu widzenia jest to możliwe do zrealizowania ale jest to wątpliwe ze strony prawnej.

4. Narzędzie dla Dziennikarzy i Fact-checkerów

Sprawdziliśmy, jak działają popularne narzędzia do weryfikacji zdjęć, takie jak Google Lens czy TinEye. Na tej podstawie uznaliśmy, że nasze rozwiązanie mogłoby działać podobnie, ale dodatkowo analizować też dźwięk i metadane pliku. Zauważyliśmy, że nawet porównując dwa podobne zdjęcia, można łatwo znaleźć różnice w metadanych, na przykład w dacie utworzenia.

5. Bezpieczeństwo w Aplikacjach Randkowych

Rozważyliśmy możliwość połączenia naszej technologii z aplikacjami randkowymi. Z technicznego punktu widzenia można byłoby analizować zdjęcia profilowe użytkowników i sprawdzać, czy nie są wygenerowane przez AI. Na razie byłby to proces ręczny (użytkownik przesyła zdjęcie do sprawdzenia), ale w przyszłości można byłoby to zautomatyzować.

IV Poziom TLR

Moduł analizy obrazów:

Testowanie: Przygotowano zestaw 100 obrazów, w tym zarówno zdjęcia wygenerowane przez AI, jak i zdjęcia wykonane przez człowieka. Testowano skuteczność systemu w wykrywaniu sztucznie wygenerowanych obrazów na podstawie ich struktury, tekstur i artefaktów cyfrowych, które często pojawiają się w obrazach stworzonych przez AI.

Wyniki: Algorytm osiągnął skuteczność 90% w rozpoznawaniu obrazów wygenerowanych przez AI, jednak w przypadku nowszych technologii generujących obrazy o wyższej jakości, skuteczność spadła do 75%.

Rozwiązanie problemu: Zwiększenie różnorodności danych treningowych oraz zastosowanie zaawansowanych algorytmów analizy artefaktów cyfrowych (np. analiza zniekształceń w cieniach, odbiciach) poprawiło wykrywalność w przypadku nowszych technologii generujących obrazy o wyższej jakości.

Moduł analizy filmów:

Testowanie: Zestaw kontrolny 50 filmów (30 wygenerowanych przez AI i 20 stworzonych przez człowieka) był analizowany pod kątem artefaktów wideo, takich jak nieregularności w cieniach, nieprawidłowe odbicia w tle oraz błędy w synchronizacji obrazu i dźwięku.

Wyniki: System wykazał 80% skuteczność w rozpoznawaniu wideo generowanych przez AI, jednak w przypadku wideo wysokiej jakości, jak deepfake, skuteczność spadła do 60%.

Rozwiązanie problemu: Ulepszenie algorytmu detekcji deepfake, szczególnie pod kątem wykrywania nienaturalnych ruchów i niespójności w synchronizacji głosu z obrazem. Dodatkowo, wprowadzenie większej liczby próbek wideo z różnych źródeł i technologii AI pozwoliło na lepsze dopasowanie algorytmu.

Moduł analizy rozmów telefonicznych:

Testowanie: Przeprowadzono testy na 100 rozmowach telefonicznych, w tym 50 wygenerowanych przez AI oraz 50 prowadzonych przez ludzi. Algorytm analizował sposób modulacji głosu, rytm mowy, a także inne charakterystyczne cechy, które mogą wskazywać na sztuczne generowanie dźwięku.

Wyniki: Skuteczność wykrywania rozmów AI wyniosła 85%, jednak w przypadku bardziej zaawansowanych technologii głosowych (np. voice cloning), skuteczność spadła do 70%.

Rozwiązanie problemu: Wprowadzenie szerszego zakresu analizy akcentów i modulacji głosu w algorytmie. Dodano także wielowymiarową analizę dźwięków, uwzględniającą również zmiany w rytmie mowy oraz wzorce intonacyjne, które są trudniejsze do odwzorowania przez AI.

Ryzyko 1: Brak zgody obu stron na nagrywanie rozmów telefonicznych

Opis ryzyka: Aby technologia mogła być skutecznie wykorzystywana do analizy rozmów telefonicznych, konieczne jest uzyskanie zgody **obu stron** rozmowy na jej nagrywanie, co jest zgodne z przepisami o ochronie danych osobowych.

Rozwiązanie: W aplikacji powinno być wprowadzone **automatyczne powiadomienie** o rozpoczęciu nagrywania rozmowy, co będzie wymagało zgody obu stron przed rozpoczęciem analizy. W przypadku braku zgody jednej ze stron, analiza nie może być przeprowadzona.

Ryzyko 2: Błędne rozpoznanie treści wygenerowanej przez AI

Opis ryzyka: Algorytm może błędnie sklasyfikować materiał generowany przez AI jako stworzony przez człowieka lub odwrotnie, co może prowadzić do fałszywych wyników i nieprawidłowych decyzji.

Rozwiązanie: Aby zminimalizować to ryzyko, system musi być testowany na różnych próbkach danych, w tym obrazach, filmach i rozmowach generowanych przez różne modele AI. Konieczne będzie również regularne **aktualizowanie bazy danych**, aby algorytm był na bieżąco z nowymi technologiami generowania treści.

Ryzyko 3: Naruszenie prywatności i bezpieczeństwa danych

Opis ryzyka: Przetwarzanie treści takich jak zdjęcia, filmy i rozmowy telefoniczne może wiązać się z przetwarzaniem danych osobowych, co stanowi ryzyko naruszenia prywatności użytkowników.

Rozwiązanie: W celu zapewnienia zgodności z przepisami **RODO**, aplikacja powinna zapewniać pełną **anonimizację danych** przed ich przetwarzaniem. Dodatkowo, wszystkie dane użytkowników powinny być szyfrowane, a dostęp do nich ograniczony tylko do osób upoważnionych.

Grupy Docelowe

1. Użytkownicy mediów społecznościowych

Naszą główną grupą docelową są globalni użytkownicy mediów społecznościowych, czyli ponad 5 miliardów ludzi aktywnie korzystających z platform takich jak Facebook, TikTok i X. Ta masowa grupa, obejmująca szeroki przekrój wiekowy, jest coraz bardziej narażona na dezinformację napędzaną przez AI, co tworzy globalny rynek dla intuicyjnych narzędzi chroniących przed fałszywymi treściami.

2. Artysci i twórcy cyfrowi

Kierujemy naszą ofertę do międzynarodowej społeczności artystów i twórców cyfrowych, których własność intelektualna jest zagrożona przez modele AI. Rynek ten, obejmujący miliony profesjonalistów silną potrzebę inwestowania w technologie, które certyfikują autentyczność i chronią ich cyfrowe dzieła.

3. Osoby starsze i narażone na oszustwa

Kluczową grupą są seniorzy, stanowiący cel dla zaawansowanych ataków z użyciem klonowania głosu czy podszywanie się pod członka rodziny „na wnuczka”. Na świecie żyje ponad 700 milionów osób powyżej 65. roku życia, a straty finansowe wynikające z tego typu oszustw są bardzo wysokie. To tworzy ogromny i pilny rynek na proste aplikacje mobilne, które zwiększają bezpieczeństwo podczas rozmów telefonicznych.

4. Dziennikarze

Naszym celem jest również rynek B2B, obejmujący dziennikarzy, fact-checkerów, menedżerów i osoby publiczne, dla których autentyczność informacji jest kluczowa. Globalny rynek narzędzi do weryfikacji faktów dynamicznie rośnie w ramach wartego setki miliardów dolarów przemysłu medialnego, co stwarza zapotrzebowanie na precyzyjne usługi chroniące przed deepfake, dezinformacją.

Możliwe ścieżki komercjalizacji

- **Model Freemium:** Podstawowa wersja narzędzia, np. rozszerzenia do przeglądarki z ograniczonymi funkcjami, mogłaby być dostępna za darmo dla masowego odbiorcy. Dostęp do zaawansowanych funkcji, takich jak szczegółowa analiza czy integracja z innymi platformami, byłby płatny.
- **Model Subskrypcyjny:** Dedykowane narzędzia dla profesjonalistów, takich jak dziennikarze i fact-checkerzy, mogłyby być oferowane w modelu subskrypcyjnym. Opłata abonamentowa zapewniałaby dostęp do pełnej funkcjonalności, aktualizacji i wsparcia technicznego. Podobnie, zaawansowana wersja aplikacji mobilnej do ochrony rozmów.

V Poziom TLR

W celu połączenia zaprogramowanych modułów zostanie zastosowany wzorzec architektoniczny MVC, który służy do organizowania struktury aplikacji. W tym etapie został przygotowany moduł odpowiedzialny za zarządzanie przepływem danych pomiędzy interfejsem użytkownika, modelem analitycznym oraz modułem odpowiedzialnym za komunikację z modelem AI. Jego zadaniem jest odbieranie danych wejściowych, przekazywanie ich do właściwych modułów analitycznych oraz zwracanie wyników użytkownikowi. W ramach etapu wykonano prace koncentrujące się na weryfikacji połączeń między modułami i przetestowaniu działania systemu w środowisku zbliżonym do rzeczywistego.

Kontroler - Kontroler został zaimplementowany w celu koordynowania pracy modułów systemu. Przeprowadzono testy jego stabilności poprzez wielokrotne uruchamianie i zatrzymywanie procesu przetwarzania danych. Weryfikowano poprawność odbioru danych, ich wstępną walidację oraz przekierowanie do odpowiedniego modułu (analiza obrazu, wideo, audio). Sprawdzone także reakcję systemu na uszkodzone dane wejściowe (np. pliki o błędnym formacie lub uszkodzone metadane). W przypadku wykrycia nieprawidłowości przeprowadzono analizę i dokonano korekt w mechanizmie weryfikacji typów danych. Po pozytywnych testach kontroler został połączony z pozostałymi modułami.

Moduł analizy obrazów - Dokonano integracji modułu analizy obrazów z kontrolerem. Przetestowano działanie modułu oraz jego współpracę z kontrolerem na próbnej bazie 1000 obrazów znalezionych na mediach społecznościowych, z czego 25% była wygenerowana sztucznie przez AI. Zweryfikowano poprawność wykrywania artefaktów charakterystycznych dla grafik generowanych algorytmicznie oraz poprawność komunikacji zwrotnej. Błędy wykryte na wstępnym etapie zostały poprawione, a test wykonano ponownie na tej samej próbce.

Moduł analizy wideo - został zintegrowany z kontrolerem. Testy wykonano na zbiorze 250 plików wideo o zróżnicowanej jakości, w tym materiałów mocno zniekształconych oraz nagrań wygenerowanych przez modele AI. Nagrania zostały wzięte z TikToka, X oraz Instagrama. Sprawdzone poprawność ekstrakcji klatek, analizę synchronizacji audio-wideo oraz wykrywanie nienaturalnych artefaktów. W przypadku błędnej klasyfikacji wykonano analizę logów, wprowadzono poprawki i ponownie przeprowadzono testy na tej samej próbce.

Moduł analizy głosu - został zintegrowany z kontrolerem i przetestowany na realnych nagraniach głosowych (naszych oraz próbek znanych osób) oraz ich syntetycznych odpowiednikach wygenerowanych przez modele AI. Zweryfikowano skuteczność wykrywania charakterystycznych cech głosu syntetycznego. Dodatkowo przetestowano reakcję systemu na zakłócenia oraz niską jakość audio. W przypadku nieprawidłowych detekcji dokonano korekt w logice analizy i ponownie przeprowadzono testy na tym samym zbiorze nagrań.